

# AI 使用说明情况

姜佳岩 · 2026-09-27

## 使用的 AI 与使用方式

这次我用了 OpenAI Codex（本次对话基于 GPT-6），帮助我理解命令、分析报错，并整理实验脚本和文稿初稿。环境安装、终端操作、截图和结果核对都在我的电脑上完成。这六份 PDF 的文字是 AI 根据操作记录整理的，提交前我还需要逐项核对数据，确认文中用第一人称写的内容是否准确。

## 真实提示词示例

| 我的提问                 | AI 帮助学习的内容                              |
|----------------------|-----------------------------------------|
| “用uv呢”               | 理解为什么要建虚拟环境、依赖应该装在哪里。                   |
| “我的部署和环境要求是否已经完成”    | 根据终端输出检查模型服务和环境是否就绪。                    |
| “带不带sglang” / 发送报错截图 | 结合报错排查 gcc、nvcc、Python.h 和 CUTLASS 的问题。 |
| “提示词怎么写”             | 学习怎样按 trace 长度构造提示词，并核对 token 数。        |
| “uri是什么”             | 弄清本地 API 地址里的 URI 是什么意思。                |

## AI 是否误导、如何核验

有一次，AI 给的 token 计数代码直接对 `apply_chat_template` 的返回对象使用 `len()`，算出来是 2。后来我发现，它数的是返回字段，而不是 token。改成统计 `result["input_ids"]` 后，结果是 3073，与 SGLang 返回的 `prompt_tokens` 一致。早期在 Ubuntu 26.04 环境中还遇到过 CUDA 编译兼容问题。此后，我主要结合具体日志、资料和实际请求结果，判断 AI 的建议是否管用。

学习 `RadixAttention` 和 `PagedAttention` 时，我参考了 AI 的解释，也对照了 SGLang、vLLM 的论文和文档来核对文稿。实验数据仍以终端截图和 `results.jsonl` 为准，AI 整理的文字不能当作测量结果。

这次的 20 条负载通过 Python 标准库的线程并发执行。Ray 已按环境要求安装，但这段脚本并未调用它。