

```

jyy@GOG: ~
wsl: 检测到 localhost 代理配置, 但未镜像到 WSL. NAT 模式下的 WSL 不支持 localhost 代理。
jyy@GOG:~$ curl http://127.0.0.1:30000/v1/models
{"object": "list", "data": [{"id": "Qwen/Qwen3-0.6B", "object": "model", "created": 1790305676, "owned_by": "sglang", "root": "Qwen/Qwen3-0.6B", "parent": null, "max_model_len": 4096}]}jyy@GOG:~$ curl -sS http://127.0.0.1:30000/v1/models | python3 -m json.tool
{
  "object": "list",
  "data": [
    {
      "id": "Qwen/Qwen3-0.6B",
      "object": "model",
      "created": 1790305699,
      "owned_by": "sglang",
      "root": "Qwen/Qwen3-0.6B",
      "parent": null,
      "max_model_len": 4096
    }
  ]
}
jyy@GOG:~$ curl -sS http://127.0.0.1:30000/v1/chat/completions \
-H 'Content-Type: application/json' \
-d '{"model": "Qwen/Qwen3-0.6B", "messages": [{"role": "user", "content": "/no_think 请用一句话介绍你自己。"}], "max_tokens": 64}' \
| python3 -m json.tool
{
  "id": "60c4c35fb84747d0895a1785dcc6dea1",
  "object": "chat.completion",
  "created": 1790305764,
  "model": "Qwen/Qwen3-0.6B",
  "choices": [
    {
      "index": 0,
      "message": {
        "role": "assistant",
        "content": "<think>\n\n\u6211\u662fAI\u52a9\u624b\u53ef\u4ee5\u4e3a\u4f60\u63d0\u4f9b\u5e2e\u52a9\u54c8\u652f\u6301\u3002",
        "reasoning_content": null,
        "tool_calls": null
      },
      "logprobs": null,
      "finish_reason": "stop",
      "matched_stop": 151645
    }
  ],
  "usage": {
    "prompt_tokens": 18,
    "total_tokens": 33,
    "completion_tokens": 15,
    "prompt_tokens_details": null,
    "reasoning_tokens": 0
  },
  "metadata": {
    "weight_version": "default"
  }
}
jyy@GOG:~$
jyy@GOG:~$

```

聊天接口已正常返回内容、finish_reason 和 usage。

图中是实验时的终端记录，放大后可以查看当时的命令和 JSON 响应。

```

def send_one(row, planned_offset):
    planned_time = start_of_experiment + planned_offset
    time.sleep(max(0, planned_time - time.perf_counter()))

python run_experiment.py.jsonl")atus"] == 200 for row in results), "条") None,
808 状态 200 输入 3073 输出 18 耗时 0.918 秒
957 状态 200 输入 3135 输出 18 耗时 0.331 秒
1036 状态 200 输入 891 输出 21 耗时 0.298 秒
2932 状态 200 输入 3125 输出 19 耗时 0.303 秒
2740 状态 200 输入 2877 输出 117 耗时 1.027 秒
3188 状态 200 输入 2989 输出 17 耗时 0.555 秒
3487 状态 200 输入 3168 输出 19 耗时 0.466 秒
4330 状态 200 输入 3149 输出 16 耗时 0.615 秒
6985 状态 200 输入 893 输出 20 耗时 0.455 秒
7757 状态 200 输入 3111 输出 18 耗时 0.381 秒
7104 状态 200 输入 3263 输出 20 耗时 0.455 秒
8668 状态 200 输入 3236 输出 17 耗时 0.262 秒
16674 状态 200 输入 896 输出 197 耗时 1.652 秒
19446 状态 200 输入 3131 输出 23 耗时 0.366 秒
12892 状态 200 输入 2819 输出 394 耗时 3.364 秒
18056 状态 200 输入 1777 输出 395 耗时 3.187 秒
20555 状态 200 输入 3002 输出 23 耗时 0.289 秒
22325 状态 200 输入 2962 输出 17 耗时 0.25 秒
22413 状态 200 输入 895 输出 319 耗时 1.806 秒
22429 状态 200 输入 3169 输出 18 耗时 0.273 秒
完成: 20 条
成功: 20 条
结果文件: results.jsonl
(sglang) jjy@GOG:~/mooncake-experiment$ |
    
```

20 / 20 条请求均返回 HTTP 200; 脚本记录了每条请求的输入、输出 token 数和总耗时。

平均到达率为 0.5 次/秒, 随机种子为 42; 总耗时均值约 0.863 秒, 中位数约 0.455 秒。

提示词由重复文字合成, 没有还原 trace 中 hash_ids 对应的前缀关系, 也没有测 TTFT。