


一次请求在 SGLang 在线推理框架中的处理过程

OpenAI-compatible API · Qwen/Qwen3-0.6B · 本地 RTX 4060



箭头表示请求的大致处理顺序，Prefill 和 Decode 都需要读写 KV。
命中已有前缀后，就能少算这部分 Prefill；本次未单独测缓存命中率或 TTFT。